


KUNDENANALYSE & MARKETINGSTRATEGIE

VON DER DATENBASIS ZUR WIRKSAMEN KAMPAGNENSTEUERUNG



- Autor: Nataliia Melnytska
- Kurs: DataSmartPoint
- Datum: Februar 2026

PROJEKTZUSAMMENFASSUNG: ZENTRALE ERKENNTNISSE

SITUATION:


Eine Kundendatenbank mit 2 240 Kunden und 27 Merkmalen wurde analysiert, um Marketingkampagnen zu optimieren.

Die Daten umfassten demografische Merkmale, Kaufhistorie sowie Reaktionen auf frühere Aktionen.


PROBLEM:

Das Fehlen einer klaren Segmentierung und eines Verständnisses der Einflussfaktoren auf die Kampagnenreaktion führt zu einer ineffizienten Budgetverwendung („Mass Marketing“).

LÖSUNG → (ML & ANALYTICS)



GRUNDLAGE DER ANALYSE: DATENBEREINIGUNG UND -ANREICHERUNG



DIE DATENQUELLE

Demografie: Alter, Einkommen (Median-Imputation), Bildungsniveau, Familienstand.

Verhalten: Recency (Tage seit dem letzten Kauf), Frequency (Anzahl der Käufe), Monetary (Ausgaben für Wein, Fleisch, Gold usw.).

Historie: Reaktionen auf 5 frühere Kampagnen, Beschwerden.

FEATURE ENGINEERING

TenureDays (Loyalität): Anzahl der Tage seit der Registrierung des Kunden.


Gesamtausgaben: Aggregierter Wert aller Ausgaben über alle Produktkategorien.

Gesamtkäufe (Total Frequency): Summe aller Käufe über Web, Katalog und Filialen.

Datenbereinigung: Vereinheitlichung von Bildungs- und Statusangaben (z. B. „Absurd“ usw. → „Ledig“).

TARGET → Reaktionen auf 5 frühere Kampagnen

ANALYSE DER EINFLUSSFAKTOREN: WAS BEWEGT DEN KUNDEN?



ANALYSE DER EINFLUSSFAKTOREN: WAS BEWEGT DEN KUNDEN?

✓ Einkommen treibt den Umsatz

Starke positive Korrelation zwischen **Einkommen** und **Gesamtausgaben** (0.66).

→ Kaufkraft ist der wichtigste Treiber des Kaufverhaltens.

✓ Kaufkanäle beeinflussen stark den Gesamtumsatz

Sehr hohe Korrelation von **Katalogkäufen** (0.78), **Ladeneinkäufen** (0.67) und **Webkäufen** (0.52) mit dem **Gesamtumsatz**.

→ Kunden mit vielen Käufen in diesen Kanälen sind besonders wertvoll.

Webbesuche ≠ Käufe - korreliert negativ mit Umsatz (-0.50).

→ Online-Aktivität zeigt Interesse, aber nicht unbedingt Kaufbereitschaft.

✓ Recency-Effekt (Letzter_Kauf_Tage)

Negative Korrelation mit **Antwort_Letzte_Kampagne** (-0.20).

→ Je länger der letzte Kauf zurückliegt, desto geringer die Reaktionswahrscheinlichkeit.

✓ Kampagnenreaktionen sagen zukünftige Reaktion voraus

Deutliche positive Zusammenhänge zwischen **Kampagne_5_Akzeptiert** (0.33), **Kampagne_3_Akzeptiert** (0.25), **Kampagne_1_Akzeptiert** (0.29) und der letzten Antwort.


✓ Kinder_zu_Hause korreliert negativ mit Umsatz (-0.56).

→ Haushalte mit Kindern zeigen zurückhaltenderes Kaufverhalten.

Einkommen	1.00	0.13	0.66
Kinder_zu_Hause	-0.43	-0.08	-0.56
Teenager_zu_Hause	0.02	-0.15	-0.14
Letzter_Kauf_Tage	-0.00	-0.20	0.02
Beschwerde	-0.03	-0.00	-0.04
Anzahl_Rabattkäufe	-0.08	0.00	-0.07
Anzahl_Webkäufe	0.38	0.15	0.52
Anzahl_Katalogkäufe	0.59	0.22	0.78
Anzahl_Ladeneinkäufe	0.53	0.04	0.67
Anzahl_WebBesuche_Monat	-0.55	-0.00	-0.50
Kampagne_1_Akzeptiert	0.27	0.29	0.38
Kampagne_2_Akzeptiert	0.09	0.17	0.14
Kampagne_3_Akzeptiert	-0.02	0.25	0.05
Kampagne_4_Akzeptiert	0.18	0.18	0.25
Kampagne_5_Akzeptiert	0.33	0.33	0.47
Antwort_Letzte_Kampagne	0.13	1.00	0.27
Alter	0.16	-0.02	0.11
TenureDays	-0.02	0.19	0.16
Bildungsniveau_num	0.10	0.08	0.06
Gesamtausgaben	0.66	0.27	1.00
	Einkommen	Kampagne_1_Akzeptiert	Gesamtausgaben

PRÄDIKTIVE ANALYTIK: MODELLIERUNG DER KAMPAGNENREAKTION

Ziel: Vorhersage der Variable „Antwort_Letzte_Kampagne“
(Variable: Ja/Nein)




Warum diese Methode?

Die Logistische Regression wurde gewählt wegen der **guten Interpretierbarkeit der Koeffizienten** und der **Zuverlässigkeit bei binärer Klassifikation**.

Fakt: In realen Geschäftsprojekten gewinnen meistens: **Logistic Regression** und **Random Forest**.

BEWERTUNG DER MODELLQUALITÄT: NACHGEWIESENE EFFEKTIVITÄT

Logistische Regression – Modell Evaluation



Train vs Test Metriken


Metrik	Training	Test	Differenz (Test-Train)
Accuracy	0.805	0.81	0.004
Precision	0.418	0.421	0.003
Recall	0.774	0.75	-0.024
F1-Score	0.543	0.54	-0.003
ROC-AUC	0.872	0.866	-0.006

BEWERTUNG DER MODELLQUALITÄT: NACHGEWIESENE EFFEKTIVITÄT

Metrik	Testwert	Marketing-Interpretation
Accuracy	0.81	Gute Gesamtgenauigkeit (bei unausgeglichene Klassen allein nicht ausreichend).
Precision	0.421	Von allen als 'Antwort' markierten Kunden reagiert nur ein Teil wirklich (Streuverluste möglich).
Recall	0.75	Das Modell findet den Großteil aller tatsächlichen Antworten (entscheidend für Marketing!).
F1-Score	0.54	Zeigt die Balance zwischen Finden von Antworten und Vermeidung von Fehlklassifikation.
ROC-AUC	0.866	Sehr gute Trennschärfe der Kundengruppen unabhängig vom Schwellenwert.

WIE ENTSCHEIDET DAS MODELL?


– EINFLUSSFAKTOREN UND TRENNSCHÄRFE DER VORHERSAGE



EINSATZ DER MODELLWAHRSCHEINLICHKEITEN FÜR MARKETINGENTSCHEIDUNGEN

Schwellenwert (Wahrscheinlichkeit)	Anteil der kontaktierten Kunden	Erwartete Response-Rate	Interpretation für die Marketingstrategie
≥ 0.8	9.4 % der Kunden	65.1 % reagieren	Sehr kleine Zielgruppe, maximale Effizienz (Premium-Selektion) → Es kann viel Budget pro Kunde investieren
≥ 0.6	18.8 % der Kunden	48.4 % reagieren	Guter Kompromiss zwischen Reichweite und Erfolgsquote → Mittleres Budget pro Kontakt
≥ 0.4	34.1 % der Kunden	36.7 % reagieren	Breite Zielgruppe mit solider Erfolgswahrscheinlichkeit → Günstige Kanäle (E-Mail, Push, Newsletter)
≥ 0.3	44.6 % der Kunden	29.7 % reagieren	Große Reichweite, aber sinkende Conversion → Nur die günstigsten Kanäle einsetzen


CLUSTERANALYSE : AUFDECKUNG VERBORGENER VERHALTENSMUSTER




Optimale Clusteranzahl:
k = 4

- ✓ Die Kundensegmente sind kompakt
- ✓ Die Kundensegmente sind klar voneinander getrennt
- ✓ Die Wahl ist datengetrieben und nicht subjektiv

VISUALISIERUNG VON CLUSTERN



KMeans Cluster – PCA 3D Visualisierung



3-D VISUALISIERUNG, PCA (PRINCIPAL COMPONENT ANALYSIS)


PCA reduziert die Vielzahl der Kundenmerkmale auf drei Hauptdimensionen, die den Großteil der Unterschiede zwischen den Kunden erklären. Dadurch können die Cluster anschaulich im 3D-Raum visualisiert werden.

Erklärte Varianz: 87.8 %

87,8 % der gesamten Information (Datenstruktur) bleiben erhalten

Die Visualisierung der Cluster im PCA-Raum stellt somit die reale Kundenstruktur nahezu verlustfrei dar.

CLUSTERVERGLEICH NACH SCHLÜSSELMERKMALEN



BENENNUNG VON CLUSTERN MIT HILFE DER RFM + RESPONSE - LOGIK

Kundenprofile: Risikogruppe und Entwicklungspotenzial

Cluster 0: Inaktiv (Schlafend)



- ✓ Recency: Hoch (lange nicht gekauft)
- ✓ Spend: Niedrig
- ✓ Frequency: Niedrig

Kunden, die seit langer Zeit das Interesse verloren haben. Benötigen Reaktivierung.

Cluster 1: Gelegenheitskäufer (Occasional)



Recency: Niedrig (kürzlich gekauft)
Spend: Niedrig
Loyalty: Niedrig

Neue Käufer mit kleinem Warenkorb.
Entwicklungspotenzial durch Nurturing

BENENNUNG VON CLUSTERN MIT HILFE DER RFM + RESPONSE-LOGIK

Kundenprofile: Umsatztreiber

Cluster 2: Premium Loyal (Premium)



- ✓ Spend: Maximal (Wein, Fleisch)
- ✓ Frequency: Hoch
- ✓ Discount Sensitivity: Niedrig

Die wertvollsten Kunden. Nicht preissensibel, schätzen Qualität und Service.

Cluster 3: Preisorientiert (Ökonomisch)




- ✓ Frequency: Hoch
- ✓ Discount Usage: Maximal
- ✓ Web Visits: Viele

Häufige Käufer und Schnäppchenjäger. Kaufen überwiegend nur bei Rabatten.

DIE STRATEGISCHE MARKETING-MATRIX

Segment	Ziel	Kanal	Konkretes Angebot
Inaktive (Schlafende) Kunden	Reaktivierung (Win-Back)	E-Mail + Gutschein	10–15% Gutschein für Rückkehr
Gelegenheitskäufer	Aktivierung und Bindung erhöhen	Personalisierte E-Mail / App Push	Produktempfehlungen + kleiner Rabatt
Premium Stammkunden	VIP-Service & Loyalität	Exklusive Angebote / Newsletter / VIP	VIP-Angebote ohne Rabatt, neue Produkte
Preisorientiert Verkäufer	Gezielte Rabattaktionen steuern	Rabatt-Mailings / Online Banner	Zeitlich begrenzte Rabattaktionen

FAZIT UND HANDLUNGSEMPFEHLUNGEN



Nächste Schritte

Der Übergang vom Massenmarketing zu einem prädiktiven Ansatz ermöglicht:



1. Reduzierung der Abwanderung (Churn) durch frühzeitige Erkennung „inaktiver“ Kunden.

Vermeidung von Kundenverlust, bevor dieser eintritt.



2. Steigerung der Marge, indem unnötige Rabatte für das „Premium“-Segment vermieden werden.

Fokus auf Wert statt auf Preis.



3. Maximierung der Conversion, indem die richtige Botschaft an den richtigen Kunden adressiert wird.

Personalisierung auf Basis von Daten zur Erhöhung der Wirksamkeit.




Es wird empfohlen, **umgehend Pilotkampagnen** für die Segmente „**Inaktive**“ (**Reaktivierung**) und „**Premium**“ (**Retention**) zu starten.

DIE GOLDENE REGEL VON ML:

**Ein Modell findet immer ein Muster.
Die Frage ist nur:
ob es das ist, das DU gesucht hast.**

Danke für Ihre Aufmerksamkeit



**Besonderer Dank dem
DataSmart Point - Team**